



FPT UNIVERSITY

OLYMPIC TRÍ TUỆ NHÂN TẠO SINH VIÊN 2026

ĐỀ THI CHÍNH THỨC

TỔNG QUAN ĐỀ THI

1	HƯỚNG DẪN CHUNG	2
1	Dữ liệu và mã nguồn mẫu	2
2	Quy định về việc sử dụng mô hình ngôn ngữ lớn	2
3	Quy định về mô hình	2
4	Định dạng tệp kết quả	2
5	Nộp bài và đánh giá kết quả	3
2	TÁC VỤ 1: XỬ LÝ NGÔN NGỮ TỰ NHIÊN	4
1	Bối cảnh thực tế & Mục tiêu	4
2	Nhiệm vụ	4
3	Mô tả dữ liệu	5
4	Hướng dẫn nộp kết quả	5
5	Tiêu chí đánh giá	6
6	Baseline và cách chạy bộ kit	6

Tài liệu hướng dẫn chung và chi tiết các tác vụ dành cho thí sinh tham dự.

HƯỚNG DẪN CHUNG

1 Dữ liệu và mã nguồn mẫu

Thí sinh tải toàn bộ dữ liệu cho cuộc thi tại đây: [Link-Download-Data](#)

Đề thi gồm có 2 tác vụ về xử lý ngôn ngữ tự nhiên và xử lý ảnh với các tập dữ liệu sau:

- `training_set`: Tập dữ liệu tập dùng để huấn luyện mô hình.
- `public_test`: Tập dữ liệu kiểm tra công khai.
- `private_test`: Tập dữ liệu kiểm tra riêng dùng để tính điểm xếp hạng.

2 Quy định về việc sử dụng mô hình ngôn ngữ lớn

- Thí sinh được phép sử dụng các công cụ LLM trong quá trình làm bài.

3 Quy định về mô hình

- Bài làm bắt buộc phải cài đặt **mô hình học máy thực sự**. Lời giải thuần giải thuật, không chứa tham số học được từ dữ liệu, sẽ không được công nhận.
- Phải **cố định seed** cho mọi thư viện có sử dụng yếu tố ngẫu nhiên (`random`, `numpy.random`, `torch`, ...) để kết quả chạy lại trùng khớp với kết quả đã nộp.
- Không được chỉnh sửa thủ công dữ liệu đầu vào hoặc tệp kết quả dưới mọi hình thức.
- Các đội phải **lưu giữ toàn bộ mã nguồn** (huấn luyện và suy luận) cùng checkpoint đã dùng để sinh ra kết quả đã nộp. Ban Tổ chức có quyền yêu cầu xuất trình bất kỳ lúc nào để hậu kiểm; đội không cung cấp được, hoặc mã nguồn không tái tạo được kết quả đã nộp, sẽ bị loại khỏi việc xét kết quả.

Riêng giới hạn về số lượng tham số mô hình được quy định trong từng tác vụ.

4 Định dạng tệp kết quả

- Tệp kết quả ở định dạng `.csv`, sử dụng bảng mã UTF-8, dùng dấu phẩy làm phân cách, **có dòng tiêu đề**, không có chỉ mục dòng.
- Tên cột và ý nghĩa từng cột được quy định riêng trong mỗi tác vụ.
- Bài nộp sai định dạng sẽ **không được tính điểm** cho lượt nộp đó.

5 Nộp bài và đánh giá kết quả

5.1 Quy trình thi

- **Năm giờ đầu:** Làm bài trên 2 tập dữ liệu `training_set` và `public_test`.
- **Giờ thứ 6:** BTC công khai tập (`private_test`). Thí sinh sử dụng mô hình của mình để tạo ra file kết quả.

5.2 Quy định về số lần nộp bài

- **Giai đoạn 1 - Public Test:** Trong 5 giờ đầu thí sinh được phép nộp tối đa 20 lần kết quả dự đoán trên tập `public_test`.
- **Giai đoạn 2 - Private Test:** Trong giờ cuối thí sinh được nộp tối đa 5 lần trên tập `private_test`.

5.3 Quy ước tên tệp nộp

- Giai đoạn Public Test: một tệp nén `[team name]_[task name]_pub.zip` (ví dụ: `Team1_task1_pub.zip`).
- Giai đoạn Private Test: một tệp nén `[team name]_[task name]_pri.zip` (ví dụ: `Team1_task2_pri.zip`).
- Bên trong tệp nén là tệp kết quả dự đoán `.csv`. Tên tệp được đặt theo quy tắc như sau `[taskname]_[public/private]_output.csv`.
- Chi tiết yêu cầu nộp bài vui lòng đọc hướng dẫn trong từng tác vụ.

5.4 Quy định về cách tính điểm

- Các thí sinh phạm quy sẽ không được chấm điểm và bị loại khỏi việc xét kết quả.
- Với mỗi tác vụ, mỗi lượt nộp bài sẽ được chấm điểm theo công thức trong tác vụ, sau đó chuẩn hóa dựa trên điểm trên scoreboard của tác vụ đó như sau:
 - Gọi điểm cao nhất trong tất cả các điểm hiện tại trên scoreboard của tác vụ là **MAX**
 - Gọi điểm của bài vừa được chấm theo công thức trong tác vụ là **SCORE**.
 - Điểm hiện lên scoreboard của thí sinh là:

$$\frac{\text{SCORE}}{\text{MAX}} \times 100\%$$

- Mỗi khi điểm **MAX** thay đổi, điểm của toàn bộ thí sinh trên scoreboard cũng sẽ được cập nhật theo công thức trên.
- Điểm cuối cùng của mỗi đội là điểm trung bình cộng của 2 tác vụ. Điểm cuối cùng sẽ được làm tròn tới 2 chữ số thập phân.

TÁC VỤ 1: XỬ LÝ NGÔN NGỮ TỰ NHIÊN

1 Bối cảnh thực tế & Mục tiêu

Ngôn ngữ trên mạng xã hội có nhiều đặc trưng khác với văn bản chuẩn: viết tắt, teencode, bỏ dấu, lặp ký tự, che từ nhạy cảm, chèn biểu tượng và dấu câu bất thường. Các hiện tượng này có thể làm giảm đáng kể độ chính xác của hệ thống phát hiện phát ngôn thù ghét nếu mô hình chỉ được huấn luyện trên văn bản sạch. Bài thi R-ViHSD được phát triển từ dữ liệu UIT-ViHSD và bổ sung một lớp dữ liệu robust bằng các phép biến đổi tổng hợp có kiểm soát. Mục tiêu không chỉ là đạt độ chính xác cao trên bài toán phân loại hate speech, mà còn đánh giá khả năng nhận biết dạng nhiễu để khuyến khích các giải pháp có tính bền vững trước dữ liệu thực tế.

2 Nhiệm vụ

Thí sinh xây dựng một hệ thống NLP đa nhiệm cho bình luận mạng xã hội tiếng Việt. Với mỗi câu đầu vào, hệ thống phải đồng thời dự đoán (i) mức độ hate speech và (ii) loại biến đổi/nhiễu của văn bản. Dữ liệu test được thiết kế để đánh giá khả năng tổng quát hóa trước teencode, bỏ dấu, kéo dài ký tự, chèn dấu câu, che ký tự và các tổ hợp nhiễu. Với mỗi mẫu văn bản x_i , hệ thống cần sinh hai đầu ra:

$$\hat{y}_i^{(h)} \in \mathcal{Y}_h, \quad \hat{y}_i^{(n)} \in \mathcal{Y}_n,$$

trong đó $\mathcal{Y}_h$ là tập nhãn hate speech và $\mathcal{Y}_n$ là tập nhãn loại nhiễu.

Task 1 - Hate Speech Classification Ba nhãn được sử dụng và định nghĩa như sau:

- **CLEAN**: nội dung bình thường, không thuộc hai nhóm bên dưới.
- **OFFENSIVE**: nội dung xúc phạm, thô tục hoặc công kích nhưng không được gán là hate speech theo annotation của bộ dữ liệu.
- **HATE**: nội dung được gán là phát ngôn thù ghét trong dữ liệu gốc.

Task 2 - Robustness/Noise Type Recognition Mỗi câu đồng thời thuộc một trong bảy loại mô tả trong bảng dưới đây:

Nhãn	Mô tả
ORIGINAL	Giữ nguyên văn bản nguồn.
NO_DIACRITICS	Loại bỏ dấu tiếng Việt.
TEENCODE	Thay thế có kiểm soát một số từ/cụm từ bằng dạng viết tắt hoặc teencode.

CHAR_REPEAT	Kéo dài một hoặc nhiều ký tự trong từ.
PUNCT_NOISE	Chèn thêm dấu câu hoặc biểu thức thường gặp trên mạng xã hội.
OBFUSCATION	Che/thay một ký tự trong từ bằng các ký hiệu như *, . hoặc _.
MIXED	Kết hợp từ hai đến ba phép biến đổi khác nhau.

3 Mô tả dữ liệu

Bộ kit chính thức cung cấp:

Tập	Số mẫu	Có nhãn?	Mục đích
training_set.csv	48,092	Có	Huấn luyện mô hình.
validation_set.csv	5,344	Có	Tự đánh giá, lựa chọn mô hình và siêu tham số.
public_test.csv	3,340	Không	Giai đoạn Public.
private_test.csv	3,340	Không	Chỉ giải nén và sử dụng được ở giai đoạn Private

Train và validation có bốn cột:

```
id,text,label,noise_type
9bcfb31ba6864a399b68,"...",CLEAN,MIXED
```

Public/Private Test chỉ có hai cột:

```
id,text
0612368174df429eafcd,"..."
```

Lưu ý:

ID không phải là feature. Mỗi ID là một token hex ngẫu nhiên 20 ký tự và chỉ dùng để ghép dự đoán với test sample. ID không mã hóa train/validation/public/private, nhãn, thứ tự, source comment hay augmentation type. Thí sinh **không được** sử dụng trực tiếp hoặc gián tiếp cột id để huấn luyện mô hình, tạo embedding, feature engineering, rule-based prediction hoặc suy luận nhãn. BTC có quyền kiểm tra source code và pipeline. Một lỗi giải khai thác ID hoặc metadata không thuộc nội dung văn bản có thể bị loại khỏi kết quả.

4 Hướng dẫn nộp kết quả

Các đội sẽ thực hiện qua 2 giai đoạn: kiểm tra công khai (public test) và kiểm tra riêng (private test). Trong mỗi giai đoạn, các đội sẽ được cung cấp dữ liệu tương ứng. Trong 05 giờ đầu, đội thi xây dựng mô hình từ `training_set` và có thể sử dụng `validation_set` để lựa chọn mô hình. `public_test` được cung cấp ngay từ đầu để sinh dự đoán và nhận phản hồi leaderboard. Public Score chỉ dùng phản hồi trong quá trình thi, không phải điểm xếp hạng cuối. Trong 01 giờ cuối, BTC phát hành/mở khóa `private_test.zip`. Đội thi sử dụng pipeline và mô hình đã phát triển để sinh dự đoán mới trên private test. Private Score dùng để xếp hạng cuối cùng.

Thí sinh phải nộp một file CSV có đúng ba cột:

```
id,pred_label,pred_noise_type
0612368174df429eafcd,HATE,OBFUSCATION
6181d0125ebf42cd8929,CLEAN,ORIGINAL
```

Yêu cầu:

- Có đúng một dòng cho mỗi ID trong `data/test.csv`.
- Không thiếu ID, không có ID thừa và không trùng ID.
- `pred_label` chỉ nhận CLEAN, OFFENSIVE hoặc HATE.
- `pred_noise_type` chỉ nhận một trong bảy nhãn noise hợp lệ.
- Không thay đổi nội dung cột `id`.

5 Tiêu chí đánh giá

Task hate speech được đánh giá bằng Macro-F1 trên ba nhãn:

$$F_{macro}^{(h)} = \frac{1}{3} \sum_{c \in \mathcal{Y}_h} F1_c.$$

Task noise recognition được đánh giá bằng Macro-F1 trên bảy nhãn:

$$F_{macro}^{(n)} = \frac{1}{7} \sum_{c \in \mathcal{Y}_n} F1_c.$$

Điểm chính thức là:

$$Score = 0.85 F_{macro}^{(h)} + 0.15 F_{macro}^{(n)}$$

Trọng số 85% dành cho nhiệm vụ hate speech để đảm bảo đây vẫn là mục tiêu NLP chính. 15% còn lại khuyến khích mô hình hiểu và xử lý nhiễu thay vì chỉ tối ưu classification trên văn bản gần chuẩn. Public leaderboard và kết quả cuối:

- **Public score:** chỉ tính trên 3,340 mẫu public dùng phản hồi trong thời gian thi và hiển thị leaderboard.
- **Private score:** tính trên 3,340 mẫu private và dùng cho xếp hạng cuối cùng.
- Trong trường hợp bằng điểm đến độ chính xác công bố, BTC có thể ưu tiên $F_{macro}^{(h)}$ cao hơn; nếu vẫn bằng nhau, áp dụng quy định phụ của BTC.

6 Baseline và cách chạy bộ kit

Baseline được cung cấp trong `starter.py` sử dụng TF-IDF character n-gram + word n-gram và hai Logistic Regression classifier độc lập. Baseline nhằm minh họa pipeline, không phải là lời giải tối ưu. Các đội được khuyến khích nghiên cứu những hướng mạnh hơn như encoder tiếng Việt, Transformer multilingual, multi-head learning, data augmentation, consistency training, class reweighting, focal loss, adversarial/noise-aware training hoặc ensemble, miễn là tuân thủ quy định về thư viện và tài nguyên của kỳ thi. Trong vòng Public Test, thí sinh chạy chương trình mẫu bằng lệnh:

```
pip install -r requirements.txt

python starter.py \
    --train data/training_set.zip \
    --val data/validation_set.zip \
    --test data/public_test.zip \
    --output public_submission.csv
```

Chương trình thực hiện huấn luyện mô hình trên `training_set.zip`, có thể sử dụng `validation_set.zip` để đánh giá mô hình, sau đó thực hiện dự đoán trên `public_test.zip`. Mỗi mẫu trong `public_test.zip` phải có đúng một dòng dự đoán. Trước khi nộp bài, thí sinh có thể kiểm tra định dạng bằng:

```
python check_submission.py \  
    --test data/public_test.zip \  
    --submission public_submission.csv
```

Sau khi kiểm tra thành công, file CSV được nén thành ZIP để nộp lên hệ thống:

```
zip public_submission.zip public_submission.csv
```

Khi vòng Private Test được mở, thí sinh sử dụng mô hình/pipeline đã hoàn thiện ở vòng Public và thực hiện inference trên `private_test.zip`:

```
python starter.py \  
    --train data/training_set.zip \  
    --val data/validation_set.zip \  
    --test data/private_test.zip \  
    --output private_submission.csv
```

Kiểm tra và đóng gói kết quả Private Test:

```
python check_submission.py \  
    --test data/private_test.zip \  
    --submission private_submission.csv  
  
zip private_submission.zip private_submission.csv
```

File cuối cùng được nộp lên hệ thống ở vòng Private là:

```
private_submission.zip  
`-- private_submission.csv
```