



## OLYMPIC TRÍ TUỆ NHÂN TẠO SINH VIÊN VIỆT NAM 2025

### VÒNG SƠ LOẠI

#### TỔNG QUAN ĐỀ THI

|                                                              |   |
|--------------------------------------------------------------|---|
| HƯỚNG DẪN CHUNG . . . . .                                    | 2 |
| TÁC VỤ 1: DỊCH THUẬT HOA – VIỆT . . . . .                    | 4 |
| TÁC VỤ 2: NHẬN DIỆN NGÔN NGỮ KÝ HIỆU CHO NGƯỜI KHIẾM THỊ . . | 7 |

# HƯỚNG DẪN CHUNG

## 1. Dữ liệu và mã nguồn mẫu

Đề thi gồm có 2 tác vụ về xử lý ngôn ngữ tự nhiên và xử lý ảnh.

- Mỗi tác vụ đều đi kèm với **một tập notebook mẫu**, trong đó đã bao gồm:
  - Mô tả tác vụ.
  - Mã nguồn của **mô hình mẫu tham khảo**.
- Bộ dữ liệu **tập huấn luyện** (`training_set`) và **tập kiểm tra công khai** (`public_test`) đã được lưu sẵn trong môi trường notebook và có thể truy cập bất kỳ lúc nào.
- Tập dữ liệu **kiểm tra riêng** (`private_test`) sẽ chỉ được mở khóa trong **giờ cuối của cuộc thi**. Thí sinh cần mật khẩu (do BTC cung cấp) để truy cập vào tập này. Việc truy cập trước giờ quy định hoặc sửa nội dung test đều bị coi là vi phạm quy chế.

## 2. Sử dụng mô hình ngôn ngữ lớn (LLM)

**Truy cập:** Thí sinh được cung cấp tài khoản truy cập vào LLM thông qua trình duyệt web trước khi bắt đầu thi. Mô hình sử dụng là `deepseek-r1-distill-qwen-32b`, hoạt động hoàn toàn offline.

**Thời gian sử dụng:** LLM chỉ được sử dụng trong **5 tiếng đầu** của kỳ thi (trong tổng thời gian thi 6 tiếng).

**Hạn chế:**

- Sau 5 tiếng đầu, quyền truy cập LLM sẽ tự động bị khóa.
- Thí sinh chỉ được dùng LLM để hỗ trợ tư duy và phát triển mô hình.

## 3. Nộp bài và đánh giá kết quả

**Quy trình thi:**

- **Giờ 0–5:** Làm bài, được phép dùng LLM và 2 tập dữ liệu `training_set` và `public_test`.
- **Giờ thứ 6:** Không còn quyền truy cập LLM. BTC công bố password cho tập dữ liệu test (`private_test`). Thí sinh sử dụng mô hình của mình để tạo ra file kết quả.

**Yêu cầu khi tạo file kết quả:**

- Không được chỉnh sửa thủ công dữ liệu đầu vào/đầu ra.
- Quá trình chạy sẽ được ghi log toàn bộ để đảm bảo minh bạch.
- Mỗi tác vụ, thí sinh cần nộp file kết quả là một file nén chấm `zip` bên trong chứa:
  1. Một file đầu ra: `output.csv` theo yêu cầu định dạng của tác vụ.
  2. Một file mã nguồn dạng `.ipynb`. Lưu ý: File kết quả đầu ra phải đảm bảo được lấy từ việc chạy tuần tự từ file `.ipynb`. Các khối mã nguồn (code cell) được chạy lần lượt từ trên xuống dưới. Bài của thí sinh chỉ hợp lệ khi mã nguồn đã nộp sinh ra kết quả tương đồng với file đầu ra.

## Cách nộp bài:

- Với mỗi lần nộp, chỉ nộp một file kết quả duy nhất qua địa chỉ được BTC công bố cho mỗi tác vụ.
- Mỗi tác vụ thí sinh có tối đa 20 lần nộp trong 5 tiếng đầu đối với tập `public_test` và tối đa 5 lần nộp trong 1 tiếng cuối đối với tập `private_test`.
- Việc nộp bài trễ sẽ không được chấp nhận.
- Thí sinh phải tạo một thư mục trên hệ thống cloud (BTC cung cấp) có tên `Final/` chứa toàn bộ chương trình tái tạo kết quả tốt nhất của 2 tác vụ:
  - Bên trong thư mục `Final/` phải có 2 thư mục con cho 2 tác vụ. Tên mỗi thư mục con tương ứng là: `Tac_vu_1` và `Tac_vu_2`. Mỗi thư mục con chứa tệp `main.py` cho tác vụ tương ứng. Khi chạy lệnh `python main.py`, chương trình phải sinh ra đúng tệp `submission.csv` tương ứng với kết quả tốt nhất của thí sinh và thời gian chạy tối đa **20 phút**.
  - Thí sinh phải cố định `seed` cho tất cả các thư viện sử dụng ngẫu nhiên (`random`, `numpy.random`, và các thư viện thuật toán như `scikit-learn`, `torch`, v.v.) để đảm bảo kết quả chạy lại là trùng khớp với kết quả nộp.

## Đánh giá:

- Kết quả chung cuộc sẽ được dựa trên kết quả của vòng kiểm tra bí mật trên tập `private_test`.
- Các thí sinh phạm quy sẽ không được chấm điểm và bị loại khỏi việc xét kết quả.
- Với mỗi tác vụ, mỗi lượt nộp bài sẽ được chấm điểm, sau đó chuẩn hóa dựa trên điểm trên scoreboard của tác vụ đó. Công thức chuẩn hóa `Norm_score` được trình bày như bên dưới. Nếu điểm `Norm_score < 0` thì sẽ được quy đổi về 0. Nếu điểm `Norm_score > 10` thì sẽ được quy đổi về 10.
- Điểm cuối cùng của mỗi đội là điểm trung bình cộng `Norm_score` của 2 tác vụ. Điểm cuối cùng sẽ được làm tròn tới 2 chữ số thập phân.

$$\text{Norm\_score} = \frac{(\text{Submission\_Score} - \text{Min\_Score})}{\text{Max\_Score} - \text{Min\_Score}} \times 100,$$

trong đó:

- `Submission_Score`: Là điểm trên scoreboard.
- `Min_Score`: Là điểm của model tối thiểu (model rất đơn giản do BTC huấn luyện và tính điểm).
- `Max_Score`: Điểm của model phức tạp được huấn luyện bởi Ban tổ chức.

# TÁC VỤ 1: DỊCH THUẬT HOA – VIỆT

## 1. Bối cảnh thực tế & Mục tiêu

Trong thời đại toàn cầu hóa, việc giao lưu kinh tế, học thuật và văn hóa giữa Việt Nam và Trung Quốc diễn ra mạnh mẽ hơn bao giờ hết. Hàng triệu tài liệu, bản tin và hội thoại cần được dịch nhanh chóng giữa hai ngôn ngữ.

Dịch máy (Machine Translation – MT) là một trong những thành tựu tiêu biểu của Trí tuệ Nhân tạo (AI), cho phép máy tính **hiểu và tái tạo ngôn ngữ con người**. Các hệ thống như Google Translate hay ChatGPT đã chứng minh sức mạnh của các mô hình học sâu trong việc xử lý ngôn ngữ tự nhiên.

Trong đề thi này, thí sinh sẽ:

- Hiểu cơ chế hoạt động của mô hình dịch máy.
- Huấn luyện mô hình dịch từ **tiếng Trung giản thể (中文)** sang **tiếng Việt**.
- Đánh giá kết quả bằng các thước đo chuẩn: **SacreBLEU**.

### 1.1 Nhiệm vụ

Xây dựng một **mô hình dịch máy tự động** có khả năng dịch **câu tiếng Trung giản thể (中文)** sang **tiếng Việt** chính xác và tự nhiên.

Thí sinh có thể lựa chọn một trong các hướng triển khai:

- **Rule-based:** Dịch theo tập luật và từ điển song ngữ.
- **Statistical Machine Translation (SMT):** Dựa trên xác suất xuất hiện đồng thời của từ/cụm từ.
- **Neural Machine Translation (NMT):** Huấn luyện mô hình học sâu Seq2Seq hoặc Transformer.

**Lưu ý:** Không được sử dụng các mô hình dịch Hoa-Việt đã được huấn luyện sẵn (pretrained models).

### 1.2 Cấu trúc dữ liệu

Để phục vụ việc huấn luyện và đánh giá mô hình dịch tiếng Trung – tiếng Việt, bộ dữ liệu được chia thành hai phần:

- **Tập huấn luyện:** `train.zh`, `train.vi`
- **Tập kiểm tra:** `test.zh`

Mỗi tệp dữ liệu chỉ có **một cột văn bản**, không có chỉ mục hoặc tiêu đề. Các dòng tương ứng giữa cặp `.zh` và `.vi` biểu thị **một cặp câu song ngữ**.

Bảng mô tả:

| Tệp dữ liệu           | Nội dung       | Ngôn ngữ    |
|-----------------------|----------------|-------------|
| <code>train.zh</code> | Tập huấn luyện | Tiếng Trung |
| <code>train.vi</code> | Tập huấn luyện | Tiếng Việt  |
| <code>test.zh</code>  | Tập kiểm tra   | Tiếng Trung |

Ví dụ:

| train.zh                                | train.vi                                                                                                 |
|-----------------------------------------|----------------------------------------------------------------------------------------------------------|
| 我会给您拿一些。<br>如果你还有什么需要的就告诉我。<br>不用担心那件事。 | Tôi sẽ mang cho bạn một ít .<br>Nếu bạn cần điều gì khác hãy cho tôi biết .<br>Đừng lo lắng về điều đó . |

### 1.3 Lưu ý định dạng

- Tất cả tệp dữ liệu được mã hóa **UTF-8**.
- Các file .zh và .vi phải có **số dòng tương ứng**.
- Không có tiêu đề, chỉ mục hay ký tự đặc biệt.
- Văn bản tiếng Trung phải dùng **Unicode giản thể chuẩn**.

### 1.4 Hướng dẫn nộp kết quả

Thí sinh cần nộp **một file CSV** gồm **2 cột**:

| tieng_trung                 | tieng_viet                                                                  |
|-----------------------------|-----------------------------------------------------------------------------|
| 我会给您拿一些。<br>如果你还有什么需要的就告诉我。 | Tôi sẽ mang cho bạn một ít .<br>Nếu bạn cần điều gì khác hãy cho tôi biết . |

### 1.5 Tiêu chí đánh giá

**SacreBLEU**: Một phiên bản chuẩn hóa để đo lường độ tương đồng giữa bản dịch máy và bản dịch tham chiếu, cung cấp kết quả nhất quán và dễ so sánh giữa các mô hình. Công thức SacreBLEU:

$$\text{SacreBLEU} = BP \cdot \exp \left( \sum_{n=1}^4 w_n \log p_n \right)$$

Trong đó:

- $p_n$ : Độ chính xác n-gram bậc  $n$ , tính bằng:

$$p_n = \frac{\sum_{\text{ngram} \in \text{hyp}_n} \min(\text{count}_{\text{hyp}}(\text{ngram}), \max_{\text{ref}} \text{count}_{\text{ref}}(\text{ngram}))}{\sum_{\text{ngram} \in \text{hyp}_n} \text{count}_{\text{hyp}}(\text{ngram})}$$

- $w_n$ : Trọng số, thường là  $1/4$  cho  $n = 1, 2, 3, 4$ .
- $BP$ : Hệ số phạt độ ngắn, tính bằng:

$$BP = \begin{cases} 1 & \text{nếu } c > r \\ \exp \left( 1 - \frac{r}{c} \right) & \text{nếu } c \leq r \end{cases}$$

- $\text{count}_{\text{hyp}}(\text{ngram})$ : Số lần xuất hiện của n-gram trong bản dịch máy.
- $\text{count}_{\text{ref}}(\text{ngram})$ : Số lần xuất hiện của n-gram trong bản dịch tham chiếu.

- $c$ : Tổng độ dài của bản dịch hệ thống.
- $r$ : Tổng độ dài của bản dịch tham chiếu.

SacreBLEU đảm bảo đánh giá chính xác và đồng nhất, đặc biệt quan trọng khi so sánh hiệu suất mô hình.

# TÁC VỤ 2: NHẬN DIỆN NGÔN NGỮ KÝ HIỆU CHO NGƯỜI KHIẾM THỊ

## 1. Bối cảnh

Trong giao tiếp hàng ngày, người khiếm thính thường sử dụng **ngôn ngữ ký hiệu** (sign language) để biểu đạt thông tin. Tuy nhiên, rào cản lớn nhất là phần lớn cộng đồng không hiểu được ngôn ngữ này, dẫn đến khó khăn trong giao tiếp và hòa nhập xã hội. Với sự phát triển của **thị giác máy tính (Computer Vision)** và **học sâu (Deep Learning)**, việc xây dựng một hệ thống **nhận diện ngôn ngữ ký hiệu tự động** trở nên khả thi. Trong cuộc thi này, thí sinh được yêu cầu xây dựng một hệ thống nhận diện ngôn ngữ ký hiệu (Sign Language Recognition) nhằm hỗ trợ người khiếm thị trong việc giao tiếp và tiếp cận thông tin. Hệ thống cần có khả năng phân loại các video ký hiệu thành các từ hoặc cụm từ tương ứng.

## 2. Mô tả bài toán

Cho một tập dữ liệu gồm các video biểu diễn các ký hiệu tay tương ứng với các từ hoặc cụm từ trong ngôn ngữ ký hiệu Việt Nam. Nhiệm vụ của bạn là xây dựng một mô hình **phân loại hình ảnh** để nhận diện ký hiệu tương ứng.

Cụ thể, mô hình nhận đầu vào là:

$$X = \{I_1, I_2, \dots, I_n\}$$

với mỗi  $I_i$  là một hình ảnh tay đang biểu diễn ký hiệu. Mục tiêu là dự đoán nhãn  $y_i$  tương ứng với từ hoặc cụm từ mà tay đó biểu diễn:

$$\hat{y}_i = f_{\theta}(I_i)$$

trong đó  $f_{\theta}$  là mô hình học sâu được huấn luyện.

## 3. Dữ liệu và mô hình baseline

- **Dữ liệu huấn luyện:** Bộ video ngắn chứa các ký hiệu tay, được gán nhãn tương ứng (ví dụ: các từ như "An ủi", "Xin lỗi", "Cảm ơn", ...).
- **Dữ liệu kiểm thử:** Tập video chưa biết nhãn, dùng để đánh giá mô hình.
- Thí sinh được cung cấp sẵn một mô hình cơ sở đã được huấn luyện sẵn trên imagenet **CRNN** – một kiến trúc mạng nơ-ron tích chập 3 chiều (3D-CNN) được thiết kế cho **nhận dạng hành động trong video** (video action recognition). Ngoài ra, thí sinh cũng có thể sử dụng các mô hình pretrained khác được cho phép. Danh sách các mô hình được cho phép ở trong file **download\_model.py**.
- Các dữ liệu được chụp trong nhiều điều kiện ánh sáng, góc quay, những người thực hiện khác nhau và màu da khác nhau để đảm bảo tính đa dạng.

## 4. Yêu cầu

- Huấn luyện mô hình phân loại hình ảnh/chuỗi hình ảnh nhận diện chính xác ký hiệu tay.
- Kết quả đầu ra là nhãn của từ hoặc cụm từ tương ứng với video đầu vào.
- Thí sinh được khuyến khích đề xuất thêm bước xử lý đầu vào (preprocessing) hoặc cải tiến mô hình để tăng độ chính xác.

## 5. Tiêu chí đánh giá

- **Tổng thể (Macro-F1):** Là giá trị trung bình của chỉ số  $F_1$  trên tất cả các lớp, giúp đánh giá cân bằng giữa *Precision* và *Recall*. Với mỗi lớp  $i$ , các chỉ số được tính như sau:

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i}, \quad \text{Recall}_i = \frac{TP_i}{TP_i + FN_i}$$

$$F1_i = 2 \times \frac{\text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

Trong đó:

- $TP$  (True Positive): số mẫu thuộc lớp dương (*positive*) được dự đoán đúng là positive.
- $TN$  (True Negative): số mẫu thuộc lớp âm (*negative*) được dự đoán đúng là negative.
- $FP$  (False Positive): số mẫu thuộc lớp âm nhưng bị mô hình dự đoán nhầm là positive.
- $FN$  (False Negative): số mẫu thuộc lớp dương nhưng bị mô hình dự đoán nhầm là negative.

và chỉ số **Macro-F1** được định nghĩa:

$$\text{Macro-F1} = \frac{1}{N} \sum_{i=1}^N F1_i$$

trong đó  $N$  là số lớp.